



Rapport de traitement des données

Titre du projet	<i>Collectez des données en respectant les normes RGPD</i>
------------------------	--

Version	Auteur	Description	Date
<i>P4</i>	<i>Bouskour Iman</i>	<i>Rapport</i>	<i>27/04/2026</i>

Introduction
Suite à une sanction de la CNIL, l'entreprise fait face à une limitation de ses traitements de données et doit désormais démontrer sa conformité au Règlement Général sur la Protection des Données (RGPD) afin d'obtenir la levée de cette restriction. Cette situation met en évidence les enjeux liés à la gestion des données personnelles et la nécessité de mettre en place des pratiques conformes aux exigences réglementaires. Dans ce contexte, une mission a été confiée afin de retravailler la base de données issue du CRM de l'entreprise. L'objectif est de garantir que les données utilisées à des fins d'analyse ne permettent plus d'identifier directement ou indirectement les individus, tout en conservant leur valeur analytique. Plus précisément, cette mission consiste à extraire les données pertinentes du CRM, à les anonymiser, à garantir l'impossibilité d'identification des clients, ainsi qu'à documenter l'ensemble des traitements réalisés.



I. Préconisations en lien avec les règles RGPD permettant de garantir à l'avenir le respect du RGPD

Afin d'assurer la conformité au RGPD, les recommandations suivantes sont proposées :

Collecte des données

- Ne collecter que les données strictement nécessaires (principe de minimisation).
- Informer clairement les clients sur l'utilisation de leurs données (transparence).
- Garantir le respect des droits des personnes (accès, rectification, suppression).
- Recueillir le consentement lorsque cela est nécessaire.

Traitement des données

- Anonymiser ou pseudonymiser les données utilisées pour l'analyse.
- Limiter l'accès aux données aux personnes autorisées uniquement.
- Mettre en place des mesures de sécurité (authentification, protection des accès).
- Définir une durée de conservation et supprimer les données inutiles.
- Documenter les traitements pour assurer la traçabilité.

Ces mesures permettent de protéger les données personnelles tout en conservant leur utilité pour l'entreprise.

II. Documentation des traitements effectués :

a. Analyse des données

L'analyse s'appuie sur le dictionnaire de données fourni

a. Données personnelles identifiées :

- Nom
- Email
- Adresse
- Num_ss
- Date_naissance
- Géolocalisation (lat, lon)

b. Données sensibles :

- Num_ss
- Groupe_sanguin

c. Données à risque :

- Employeur
- Revenus
- Nombre_enfants

d. Données exploitables :

- ❖ Metier
- ❖ Type_conduite
- ❖ Formule
- ❖ Age_vehicule
- ❖ Points_perdus

b. Requête SQL

La requête SQL a été conçue afin d'extraire uniquement les données nécessaires à l'analyse tout en respectant les principes du RGPD.

Requête:

```
SELECT
    ROW_NUMBER() OVER () AS client_id,
    sexe,
    date_naissance,
    tarif_devis,
    age_vehicule,
    type_conduite,
    formule,
    enfant_conduite_accompagne,
    nombre_enfants,
    revenus,
    type_vehicule,
    usage_vehicule,
FROM base_client
WHERE etat_dossier = 'complet'
AND strftime('%Y', date_demande) = '2022';
```



a. Documentation de la requête SQL

La requête SQL a été conçue afin d'extraire uniquement les données nécessaires à l'analyse tout en respectant les principes du RGPD.

b. Sélection des colonnes

Les variables sélectionnées sont les suivantes :

- sexe,
- date_naissance,
- tarif_devis
- age_vehicule,
- type_conduite,
- formule,
- enfant_conduite_accompagne,
- nombre_enfants,
- revenus,
- type_vehicule,
- usage_vehicule,

Ces variables ont été choisies car elles sont pertinentes pour l'analyse commerciale et ne permettent pas d'identifier directement un individu

❖ Création d'un identifiant anonyme

La fonction ROW_NUMBER() a été utilisée afin de générer un identifiant technique (client_id):

- Cet identifiant est artificiel
- Il ne permet pas de relier les données à une personne réelle

Cela contribue à l'anonymisation des données.

❖ Filtrage des données

Deux conditions ont été appliquées :

- etat_dossier = 'complet'
permet de ne conserver que les dossiers exploitables
- strftime('%Y', date_demande) = '2022'
permet de limiter l'analyse à l'année 2022

❖ Respect des principes RGPD

La requête respecte plusieurs principes du RGPD :

- Minimisation des données : seules les variables nécessaires sont sélectionnées
- Finalité : les données sont utilisées uniquement dans un cadre d'analyse
- Protection des données personnelles : exclusion des données identifiantes


c. Préparation des données (Power Query)

La préparation des données a été réalisée à l'aide de Microsoft Power Query, intégré à Excel, permettant de nettoyer, transformer et structurer les données.

a. Étapes de préparation des données

❖ Import des données

Le fichier CSV issu de l'extraction SQL a été importé dans Power Query. Les données ont ensuite été structurées pour être exploitables (gestion du séparateur et des types de données).



❖ Gestion des en-têtes

Le fichier initial ne contenait pas d'en-têtes de colonnes.

Les variables numériques ont été converties au format approprié (nombre décimal) afin de permettre leur traitement



123 client_id	A ^B C sexe	date_naissance	A ^B C tarif_devis	A ^B C age_vehicule	A ^B C type_conduite	A ^B C formule	123 enfant_conduite_accompagne
1	F	25/09/1999	323.39	7.0	Highly Urban/ Urban	dev_integral	
2	F	28/01/1932	257.56	1.0	Highly Urban/ Urban	dev_express	

❖ Transformation des types de données

Les variables numériques ont été converties au format nombre

A ^B C age_vehicule	1.2 age_vehicule
10.0	10
8.0	8
9.0	9
	1
	16

est devenu

Les valeurs manquantes (null) ont été identifiées et traitées

d. Anonymisation des données(Power Query)

a. Transformation de la variable « âge » en « tranche d'âge » (avec formule)

❖ Étape 1 : Vérification du type de données

La colonne **date_naissance** a été vérifiée et convertie au format **Date** afin de permettre les calculs.

❖ Étape 2 : Calcul de l'âge

Une colonne intermédiaire **age** a été créée avec la formule suivante :

Colonne personnalisée

Ajoutez une colonne calculée à partir des autres colonnes.

Nouveau nom de colonne

age

Formule de colonne personnalisée

= Date.Year(DateTime.LocalNow()) - Date.Year([date_naissance])

[

Colonnes disponibles

id_anonyme
sexe
revenus
nombre_enfants
type_vehicule
usage_vehicule
age_vehicule

<< Insérer

En savoir plus sur les formules Power Query

✓ Aucune erreur de syntaxe n'a été détectée.


OK

Annuler

Cette formule permet de calculer l'âge en années à partir de la date de naissance.

❖ Étape 3 : Création de la tranche d'âge

Une nouvelle colonne **Tranche d'âge** a été créée à l'aide d'une formule conditionnelle en langage M :



Colonne personnalisée

Ajoutez une colonne calculée à partir des autres colonnes.

Nouveau nom de colonne

Tranche d'âge

Formule de colonne personnalisée

```
=if [Age] = null then "Non renseigné"  
else if [Age] < 25 then "[0_25]"  
else if [Age] < 40 then "[25_40]"  
else if [Age] < 60 then "[40_60]"  
else "[60 et +]"
```

Colonnes disponibles

- client_id
- sexe
- date_naissance
- tarif_devis
- age_vehicule
- type_conduite
- formule

<< Insérer

En savoir plus sur les formules Power Query

✓ Aucune erreur de syntaxe n'a été détectée.

OK Annuler

❖ Étape 4 : Vérification des résultats

La colonne **Tranche d'âge** a été contrôlée afin de s'assurer que seules les modalités suivantes sont présentes :

ABC	Tranche d'âge
123	[25_40]
	[60 et +]
	[40_60]
	[0_25]

❖ Étape 5 : Suppression des colonnes sensibles

Une fois la transformation effectuée :

- La colonne **date_naissance** a été supprimée car trop précise
- La colonne **age** peut également être supprimée pour ne conserver que la donnée agrégée

b. Transformation de la variable « revenus » en « tranche de revenus »

❖ Étape 1 : Vérification du type de données

La colonne **revenus** a été vérifiée et convertie au format **Nombre (entier ou décimal)** afin de permettre les comparaisons numériques.

❖ Étape 2 : Gestion des valeurs manquantes

Les valeurs nulles ont été prises en compte afin d'éviter les erreurs de traitement. Lorsque la valeur de revenus est absente, elle est classée dans la catégorie « **Non renseigné** ».

❖ Étape 3 : Création de la tranche de revenus

Une nouvelle colonne **revenus_tranche** a été créée à l'aide de la formule suivante en langage M :

Colonne personnalisée

Ajoutez une colonne calculée à partir des autres colonnes.

Nouveau nom de colonne

Revenus_tranche

Formule de colonne personnalisée

```
=if [revenus] = null then "Non renseigné"  
else if Number.From([revenus]) < 20000 then "[0_20k]"  
else if Number.From([revenus]) < 40000 then "[20k_40k]"  
else if Number.From([revenus]) < 60000 then "[40k_60k]"  
else "[60k et +]"
```

[En savoir plus sur les formules Power Query](#)

✓ Aucune erreur de syntaxe n'a été détectée.

OK

Annuler

Colonnes disponibles

client_id
sexe
date_naissance
tarif_devis
age_vehicule
type_conduite
formule

<< Insérer

Cette formule permet de regrouper les revenus en classes homogènes, tout en conservant leur utilité analytique.

❖ Étape 4 : Vérification des résultats

La colonne **revenus_tranche** a été contrôlée afin de s'assurer que seules

les catégories suivantes sont présentes :

ABC	Revenus_tranche
123	[60k et +]
	[40k_60k]
	[20k_40k]
	[0_20k]
	Non renseigné



❖ Étape 5 : Suppression de la donnée brute

Une fois la transformation effectuée, la colonne **revenus** a été supprimée afin de ne conserver que la version agrégée.

c. Transformation de la variable « nombre d'enfants » en variable binaire

❖ Étape 1 : Vérification du type de données

La colonne **nombre_enfants** a été vérifiée et convertie au format **Nombre** afin de permettre les comparaisons.

❖ Étape 2 : Gestion des valeurs manquantes

Les valeurs nulles ont été prises en compte pour éviter les erreurs de traitement. Lorsqu'aucune information n'est disponible, la valeur est classée dans la catégorie « **Non renseigné** ».

❖ Étape 3 : Création de la variable transformée

Une nouvelle colonne **enfants** a été créée à l'aide de la formule suivante en langage M :



Cette formule permet de remplacer une donnée quantitative précise par une information binaire plus générale.

❖ Étape 4 : Vérification des résultats

La colonne **enfants** a été contrôlée afin de vérifier que seules les modalités suivantes apparaissent :



ABC 123	Enfants	
	Oui	
	Oui	
	Oui	
	Non	

- Oui
- Non
- Non renseigné

❖ Étape 5 : Suppression de la donnée brute

Une fois la transformation terminée, la colonne **nombre_enfants** a été supprimée afin de ne conserver que la version simplifiée.

Conclusion

La mission a permis de mettre en œuvre un processus complet de traitement et d'anonymisation des données issues du CRM, en conformité avec les exigences du RGPD.

De l'extraction des données à leur transformation à l'aide de Microsoft Power Query, les différentes étapes ont permis de supprimer les données personnelles et sensibles, de réduire le niveau de précision des informations et de limiter les risques de ré-identification.

Le jeu de données obtenu est ainsi exploitable à des fins d'analyse tout en garantissant la protection des individus. Ce travail met en évidence l'importance d'intégrer les principes du RGPD dès la conception des traitements de données, notamment à travers une approche de type « privacy by design ».

Au-delà de l'aspect technique, cette mission souligne les enjeux majeurs liés à la confidentialité des données. Les entreprises doivent aujourd'hui concilier l'exploitation des données avec le respect des droits des personnes, dans un contexte réglementaire de plus en plus exigeant. Si ces contraintes peuvent limiter certaines analyses, elles constituent néanmoins un levier essentiel pour renforcer la confiance des utilisateurs et sécuriser les pratiques de gestion des données.